

# Inteligência Artificial

## Aula 28- Redes Neurais (Simulação Perceptron) <sup>1</sup>

Sílvia M.W. Moraes

Escola Politécnica - PUCRS

October 25, 2018

---

<sup>1</sup>Este material não pode ser reproduzido ou utilizado de forma parcial sem a permissão dos autores.


# Sinopse

- Nesta aula, mostramos a simulação de uma **rede neural Perceptron**.
- Este material foi construído usando os algoritmos vistos em aula e disponíveis no moodle.

# Sumário

## 1 Introdução à Redes Neurais Perceptron


# Redes Neurais: Neurônio Artificial



- Entradas:  $x_1, \dots, x_n$ : valores do domínio;  $x_0$ : entrada extra, é sempre 1 (bias).
- Pesos sinápticos: armazenam o conhecimento adquirido pela rede.
  - $w_{kn}$ , onde  $k$  é o neurônio e o  $n$ , a entrada;  $w_{k0}$ : peso do bias
- $v_k$ : campo local induzido, corresponde a uma soma ponderada (pelos pesos) das entradas do neurônio

$$v_k = \sum_{i=0}^n w_{ki} \times x_i$$

# Redes Neurais: Neurônio Artificial



- $y_k$ : saída do neurônio  $k$  é definido pela função de transferência, a qual simula a polaridade da membrana pós-sináptica.
  - $y_k = Q(v_k)$ , onde a função de transferência pode ser:  
 limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$

# Redes Neurais: Treinamento

- Os **ciclos de treinamento** de uma rede são medidos em **épocas**.
- Uma **época** corresponde a **passagem de todos os padrões do conjunto de treino uma vez pela rede**.
- Para treinar uma rede são necessárias várias épocas.

# Redes Neurais: Treinamento

- **Rede Perceptron (Adaline):**
  - **Algoritmo de Treinamento: Regra Delta**
  - Sendo  $X = \{(amostra_1, d_1), (amostra_2, d_2), \dots\}$  o conjunto de treino e  $\eta$ , a taxa de aprendizagem (deve ser positiva).

Inicializa os pesos  $w$  da rede com zero

Repetir até encontrar erro zero para todas as amostras{

  epocas = epocas + 1

  Para cada par de  $X$  {

    Para cada atributo  $x_i$  da amostra, onde  $i = 1$  a  $n$ {

      Para cada neurônio  $k$  da rede{

$$v_k = w_{ki} * x_i$$

$$y_k = Q(v_k)$$

$$\text{erro}_k = d_k - y_k$$

$$\Delta w_{ki} = \eta * \text{erro}_k * x_i$$

$$w_{ki} = w_{ki} + \Delta w_{ki}$$

      }

    }


  }

}

# Redes Neurais: Treinamento

- **Rede Perceptron (Adaline):**
  - Exemplo: OR


x1	x2	d
0	0	0
0	1	1
1	0	1
1	1	1





# Redes Neurais: Treinamento (Época 1)

- **Pesos** inicializados com zero:  $w_{10} = 0, w_{11} = 0, w_{12} = 0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times 0 + 0 \times 0 + 0 \times 0 = 0$
- $y_1 = Q(v_1) = Q(0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)

- $erro_1 = d_1 - y_1 = 0 - 1.0 = -1.0$
- $w_{10} = w_{10} + \eta \times erro_1 \times x_0 = 0.0 + 1 \times -1.0 \times 1 = -1.0$
- $w_{11} = w_{11} + \eta \times erro_1 \times x_1 = 0.0 + 1 \times -1.0 \times 0 = 0.0$
- $w_{12} = w_{12} + \eta \times erro_1 \times x_2 = 0.0 + 1 \times -1.0 \times 0 = 0.0$

## Redes Neurais: Treinamento (Época 1)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 0.0, w_{12} = 0.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 0 \times 0.0 + 1 \times 0.0 = -1.0$
- $y_1 = Q(v_1) = Q(-1.0) = 0.0$

- Ajuste dos pesos (Aplicando a regra delta)

- $erro_1 = d_1 - y_1 = 1 - 0.0 = 1.0$
- $w_{10} = w_{10} + \eta \times erro_1 \times x_0 = -1.0 + 1 \times 1.0 \times 1 = 0.0$
- $w_{11} = w_{11} + \eta \times erro_1 \times x_1 = 0.0 + 1 \times 1.0 \times 0 = 0.0$
- $w_{12} = w_{12} + \eta \times erro_1 \times x_2 = 0.0 + 1 \times 1.0 \times 1 = 1.0$

# Redes Neurais: Treinamento (Época 1)

- **Pesos atuais:**  $w_{10} = 0.0, w_{11} = 0.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times 0.0 + 1 \times 0.0 + 0 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 1)

- **Pesos atuais:**  $w_{10} = 0.0, w_{11} = 0.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$



- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times 0.0 + 1 \times 0.0 + 1 \times 1.0 = 1.0$
- $y_1 = Q(v_1) = Q(1.0) = 1.0$


- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 1)

- Erro Acumulado para época 1 :
  - Erro Geral:
    - $= \text{abs}(\text{erroEntrada1}) + \text{abs}(\text{erroEntrada2}) + \text{abs}(\text{erroEntrada3}) + \text{abs}(\text{erroEntrada4}) =$
    - $= \text{abs}(-1.0) + \text{abs}(1.0) + \text{abs}(0.0) + \text{abs}(0.0)$
    - $= 2.0$
- Como ainda há erro, o algoritmo prossegue ...

# Redes Neurais: Treinamento (Época 2)

- **Pesos atuais:**  $w_{10} = 0.0, w_{11} = 0.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 0 \times 0.0 + 0 \times 1.0 + 1 \times 0.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)

- $erro_1 = d_1 - y_1 = 0 - 1.0 = -1.0$
- $w_{10} = w_{10} + \eta \times erro_1 \times x_0 = 0.0 + 1 \times -1.0 \times 1 = -1.0$
- $w_{11} = w_{11} + \eta \times erro_1 \times x_1 = 0.0 + 1 \times -1.0 \times 0 = 0.0$
- $w_{12} = w_{12} + \eta \times erro_1 \times x_2 = 1.0 + 1 \times -1.0 \times 0 = 1.0$

## Redes Neurais: Treinamento (Época 2)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 0.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 0 \times 0.0 + 1 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 2)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 0.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$



- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 1 \times 0.0 + 0 \times 1.0 = -1.0$
- $y_1 = Q(v_1) = Q(-1.0) = 0.0$


- Ajuste dos pesos (Aplicando a regra delta)

- $erro_1 = d_1 - y_1 = 1 - 0.0 = 1.0$
- $w_{10} = w_{10} + \eta \times erro_1 \times x_0 = -1.0 + 1 \times 1.0 \times 1 = 0.0$
- $w_{11} = w_{11} + \eta \times erro_1 \times x_1 = 0.0 + 1 \times 1.0 \times 1 = 1.0$
- $w_{12} = w_{12} + \eta \times erro_1 \times x_2 = 1.0 + 1 \times 1.0 \times 0 = 1.0$



# Redes Neurais: Treinamento (Época 2)

- **Pesos atuais:**  $w_{10} = 0.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$



- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times 0.0 + 1 \times 1.0 + 1 \times 1.0 = 2.0$
- $y_1 = Q(v_1) = Q(2.0) = 1.0$


- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 2)

- Erro Acumulado para época 2 :
  - Erro Geral:
    - $= \text{abs}(\text{erroEntrada1}) + \text{abs}(\text{erroEntrada2}) + \text{abs}(\text{erroEntrada3}) + \text{abs}(\text{erroEntrada4}) =$
    - $= \text{abs}(-1.0) + \text{abs}(0.0) + \text{abs}(1.0) + \text{abs}(0.0)$
    - $= 2.0$
- Como ainda há erro, o algoritmo prossegue ...

# Redes Neurais: Treinamento (Época 3)

- **Pesos atuais:**  $w_{10} = 0.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times 0.0 + 0 \times 1.0 + 0 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)

- $erro_1 = d_1 - y_1 = 0 - 1.0 = -1.0$
- $w_{10} = w_{10} + \eta \times erro_1 \times x_0 = 0.0 + 1 \times -1.0 \times 1 = -1.0$
- $w_{11} = w_{11} + \eta \times erro_1 \times x_1 = 1.0 + 1 \times -1.0 \times 0 = 1.0$
- $w_{12} = w_{12} + \eta \times erro_1 \times x_2 = 1.0 + 1 \times -1.0 \times 0 = 1.0$

## Redes Neurais: Treinamento (Época 3)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 0 \times 1.0 + 1 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

## Redes Neurais: Treinamento (Época 3)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 1 \times 1.0 + 0 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

## Redes Neurais: Treinamento (Época 3)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$



- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 1 \times 1.0 + 1 \times 1.0 = 1.0$
- $y_1 = Q(v_1) = Q(1.0) = 1.0$


- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 3)

- Erro Acumulado para época 3 :
  - Erro Geral:
    - $= \text{abs}(\text{erroEntrada1}) + \text{abs}(\text{erroEntrada2}) + \text{abs}(\text{erroEntrada3}) + \text{abs}(\text{erroEntrada4}) =$
    - $= \text{abs}(-1.0) + \text{abs}(0.0) + \text{abs}(0.0) + \text{abs}(0.0)$
    - $= 1.0$
  - Como ainda há erro, o algoritmo prossegue ...

## Redes Neurais: Treinamento (Época 4)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 0 \times 1.0 + 0 \times 1.0 = -1.0$
- $y_1 = Q(v_1) = Q(-1.0) = 0.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 0 - 0.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.



## Redes Neurais: Treinamento (Época 4)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 0 \times 1.0 + 1 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

## Redes Neurais: Treinamento (Época 4)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$




- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 1 \times 1.0 + 0 \times 1.0 = 0.0$
- $y_1 = Q(v_1) = Q(0.0) = 1.0$

- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

## Redes Neurais: Treinamento (Época 4)

- **Pesos atuais:**  $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$
- limiar:  $Q(v_k) = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{caso contrário} \end{cases}$ , taxa de aprendizagem:  $\eta = 1$



- $v_1 = x_0 \times w_{10} + x_1 \times w_{11} + x_2 \times w_{12}$
- $v_1 = 1 \times -1.0 + 1 \times 1.0 + 1 \times 1.0 = 1.0$
- $y_1 = Q(v_1) = Q(1.0) = 1.0$


- Ajuste dos pesos (Aplicando a regra delta)
  - $erro_1 = d_1 - y_1 = 1 - 1.0 = 0.0$
  - quando o erro é zero, não há ajuste de pesos.

# Redes Neurais: Treinamento (Época 4)

- Erro Acumulado para época 4 :
  - Erro Geral:
    - $= \text{abs}(\text{erroEntrada1}) + \text{abs}(\text{erroEntrada2}) + \text{abs}(\text{erroEntrada3}) + \text{abs}(\text{erroEntrada4}) =$
    - $= \text{abs}(0.0) + \text{abs}(0.0) + \text{abs}(0.0) + \text{abs}(0.0)$
    - $= 0.0$
  - O algoritmo pára.
- Resultado:
  - O algoritmo encontrou os pesos adequados:  
 $w_{10} = -1.0, w_{11} = 1.0, w_{12} = 1.0$

# Redes Neurais: Generalização

- A rede está pronta para ser testada (ou usada).
  - 1 Carrega-se, na topologia da rede, os pesos encontrados na fase de treinamento.



- 2 Esta fase implementa apenas a propagação. Informa-se novos valores para as entradas e a rede gera a saída correspondente.